Predicciones de Muertes por Covid

Leire Gonzalez, Aroa Gómez, Udane Saitua

January 2026

1 Resumen

Este trabajo aborda la predicción de la mortalidad diaria por COVID-19 en Euskadi mediante el uso de arquitecturas avanzadas de aprendizaje profundo. Utilizando los registros oficiales de Open Data Euskadi, se ha planteado un problema de regresión supervisada basado en ventanas temporales de siete días para capturar la dependencia secuencial de la pandemia.

A lo largo del proyecto, se han comparado modelos de diversa naturaleza: desde perceptrones multicapa (MLP) y redes recurrentes (LSTM, GRU), hasta un enfoque innovador basado en Redes de Grafos Neuronales (GNN) que utiliza una topología de correlación funcional entre zonas de salud. Los resultados demuestran que las redes LSTM son óptimas para gestionar la inercia temporal en escenarios cronológicos. A su vez, hemos decidido hacer un mayor análisis de los datos mediante el modelo GNN con el fin de integrar la dimensión espacial. En este caso esta parte del análisis la hemos realizado con los datos de los contagios por barrio, ya que no disponíamos de los datos suficientes de fallecidos por barrio y nos encontramos con un problema de escasez (sparsity). Si bien hemos observado que obtiene buenos resultados al analizar los contagios para cada barrio, estos no son comparables con los resultados del LSTM, ya que estos son para el conjunto global, no para zonas.

Este estudio no solo valida la eficacia de las redes recurrentes para el análisis epidemiológico, sino que también analiza cómo factores externos como la vacunación y el ruido administrativo condicionan la capacidad de generalización de los modelos.

2 Descripción del problema

El objetivo de este proyecto es predecir el número de muertes por COVID-19 de un día usando los datos de los 7 días anteriores. Esto se plantea como un problema de regresión supervisada, donde la variable objetivo es el número de fallecimientos y las variables predictoras incluyen tanto los valores históricos de

muertes como otras características relacionadas con la epidemia.

Formalmente, se trata de un problema de predicción de secuencias o de series temporales, donde los datos presentan dependencia temporal: el valor de un día está altamente correlacionado con los días previos. Esto implica que no se pueden tratar las observaciones de manera independiente, sino que el modelo debe capturar patrones y tendencias a lo largo del tiempo para realizar predicciones precisas.

Resolver este problema permite anticipar la evolución de la pandemia y planificar recursos de manera más eficiente. Desde el punto de vista metodológico, requiere técnicas que manejen secuencias, como ventanas deslizantes de datos, y modelos capaces de capturar dependencias temporales, desde regresiones lineales con retardos hasta redes neuronales recurrentes (LSTM o GRU).

En resumen, el problema central es aprender patrones temporales en series de datos multivariantes para predecir muertes diarias de COVID-19, considerando la correlación entre días consecutivos y la influencia de distintas variables epidemiológicas.

3 Descripción de los datos

Los datos utilizados en este proyecto provienen del conjunto Evolución del coronavirus (COVID-19) en Euskadi, publicado por el Departamento de Salud del Gobierno Vasco en la plataforma Open Data Euskadi. Este recurso reúne información diaria y estructurada sobre la evolución de la pandemia en la Comunidad Autónoma del País Vasco.

Este dataset está disponible en múltiples formatos reutilizables (CSV, JSON, XLSX y XML), lo que permite su uso en análisis automatizados y en entornos de programación científica. En nuestro caso, elegimos utilizar los datos en formato JSON ya que nos proporciona más facilidades a la hora de trabajar con python.

Se encuentran distintos archivos que contienen información diaria sobre distintos aspectos de la pandemia.

Las características estructurales más importantes de estos archivos son que cada registro tiene un campo date, lo que facilita la alineación temporal entre diferentes fuentes de datos, y que las métricas son principalmente numéricas.

En esta gráfica podemos visualizar los datos más importantes a tener en cuenta:

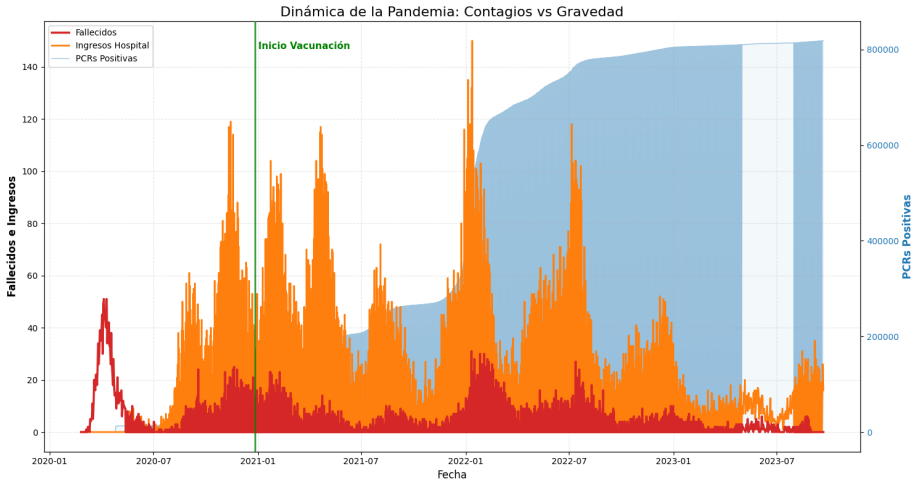

Figure 1: Evolución de la pandemia

4 Diseño e Implementación

4.1 Preprocesamiento

El preprocesamiento de los datos constituye una fase crítica de la tarea, ya que permite integrar múltiples fuentes heterogéneas, corregir inconsistencias temporales y preparar la información para su uso en distintos modelos de aprendizaje profundo.

Como ya se ha comentado, los datos provienen de distintos conjuntos en formato JSON. Estas fuentes presentan diferentes estrucutras internas, lo que hace necesaria una etapa de normalización y fusión cuidadosa.

Todas las variables temporales se unificaron mediante la conversión explícita de la columna date al tipo datetime. Durante este proceso también se eliminaron tuplas con fechas inválidas y se eleminó cualquier información de zona horaria para garantizar la compatibilidad en las operaciones de fusión entre conjuntos.

Una vez realizado esto, cada conjunto de datos fue procesado de forma específica. Se extrajeron datos sobre los fallecimientos, hospitalizaciones, estado epidérmico, datos demográficos y demás.

Todos los conjuntos procesados se fusionaron con el conjunto principal de fallecimientos. Posteriormente, los datos de ordenaron cronológicamente, lo cual es imprencindible para los pasos posteriores de imputación y entrenamiento de los modelos secuenciales.

Dado que las distintas fuentes presentan ausencias temporales, se aplicó una

estrategia de imputación según el tipo de variable. Con las variables continuas se optó por agregar el mismo valor que el día anterior. En cuanto a las variables discretas, se imputaron con valor cero.

Además, se decidió añadir una variable booleana denominada hay vacuna, que indica la presencia o ausencia de vacunación en la población. Esta característica toma valor 0 antes del 27 de diciembre de 2020 y 1 a partir de esa fecha, permitiendo al modelo capturar el impacto del inicio de la campaña de vacunación.

Lo último a realizar fue el escalado de las variables. Estas fueron escaladas en le rango [0,1] mediante nornmalización MinMax. Este paso es especialmente importante para el entrenamiento de redes neuronales recurrentes, ya que mejora la estabilidad numérica y acelera la convergencia del modelo.

4.2 Ventanas Temporales

Dado que nuestro modelo tiene que trabajar con series temporales de 7 días, es imprescindible la construcción de secuencias temporales mediante ventanas deslizantes. Cada muestra de entrada contiene la evolución de todas las variables durante una semana, y la salida asociada corresponde al número de fallecimientos del día siguiente.

4.3 Partición del conjunto

Para la partición del conjunto, se han querido trabajar y analizar dos estrategias: una partición cronológica, y otra aleatoria.

En cuanto a la cronológica, podría decirse que simula un escenario realista de predicción en el que el modelo solo dispone de información pasada para estimar valores futuros. Sin embargo, este enfoque es sensible a los cambios de distribución. Como bien sabemos, a finales de la pandemia, el número de fallecidos era mucho menor debido a distintos factores. Como resultado, una partición temporal implica que el modelo se entrene principalmente con periodos caracterizados por valores elevados de fallecimientos, mientras que el conjunto de prueba corresponde a una etapa en la que dichos valores son considerablemente menores.

Esta diferencia de distribución entre las fases de entrenamiento y prueba puede dificultar la capacidad del modelo para generalizar adecuadamente, ya que se enfrenta en la evaluación a un régimen de datos distinto al observado durante el aprendizaje.

En una partición aleatoria, conseguimos hacer frente a esta problemática, pero perdemos esa esencia de las series temporales.

Debido a este dilema, se optó por implementar las dos estartegias y visualizar cuál proporcionaba mejor resultado

4.4 Baselines Propuestos

Con el fin de evaluar la utilidad real de los modelos de aprendizaje profundo, se implementaron dos modelos de referencia o *baselines*. Estos modelos establecen un marco comparativo para determinar si las arquitecturas complejas son capaces de extraer patrones que superen a las aproximaciones estadísticas más simples.

- **Baseline de Persistencia (Naive):** Este modelo se basa en la hipótesis de la "inercia temporal". Predice que el valor de fallecimientos para el día t será exactamente el mismo que el observado en el día $t-1$. Es un referente crítico en series temporales con alta correlación diaria; si un modelo avanzado no logra batir la persistencia, significa que no está aprendiendo la dinámica de la pandemia, sino simplemente replicando el último dato con retraso. En nuestros resultados, este modelo genera una gráfica desplazada un paso en el tiempo respecto a la real.

- **Baseline de Regresión Ridge:** Es un modelo de regresión lineal que incluye una penalización $L2$ para evitar el sobreajuste (*overfitting*). A diferencia de la persistencia, este modelo sí utiliza toda la ventana de los 7 días previos para realizar una combinación lineal de las variables. Representa la capacidad de un modelo matemático clásico para capturar tendencias. Sirve para demostrar si la relación entre los días previos y el futuro es puramente lineal o si, por el contrario, requiere de la no linealidad que aportan las redes neuronales.

4.5 Modelos de Predicción

Para comparar el rendimiento de los distintos enfoques y evaluar la capacidad de las redes para capturar dependencias temporales, se implementaron cuatro arquitecturas distintas: un modelo base no recurrente (MLP), dos estructuras de redes recurrentes (LSTM y GRU) y una variante avanzada con mecanismo de atención.

- **MLP (Multi-Layer Perceptron):** Es un modelo *feedforward* que sirve como línea base (*baseline*) de aprendizaje profundo. A diferencia de las redes recurrentes, el MLP no tiene memoria interna. Para procesar la ventana temporal de 7 días, el modelo "aplana" (*flatten*) los datos, convirtiendo la matriz de entrada en un vector unidimensional. Consta de capas densas con funciones de activación ReLU y capas de *Dropout* para prevenir el sobreajuste. Su principal limitación es que trata cada día de

la ventana como una variable independiente, perdiendo la estructura secuencial de los datos.

- **LSTM (Long Short-Term Memory):** Es un tipo de red neuronal recurrente (RNN) diseñada específicamente para el modelado de secuencias temporales. Su arquitectura resuelve el problema del desvanecimiento del gradiente mediante el uso de "puertas" (*gates*) que controlan el flujo de información, permitiendo a la red decidir qué datos mantener y cuáles olvidar a largo plazo.

  Nuestra red consta de capas recurrentes apiladas y una capa final totalmente conectada (*fully connected*). Esta última capa toma el estado oculto del último paso temporal de la secuencia y produce una salida escalar que corresponde a la predicción del número de fallecidos para el día siguiente.

- **GRU (Gated Recurrent Unit):** La unidad GRU es una variante simplificada de la LSTM. Combina las puertas de olvido y de entrada en una sola "puerta de actualización" (*update gate*). Al tener menos parámetros que una LSTM, la GRU es computacionalmente más eficiente y tiende a converger más rápido, manteniendo una capacidad similar para capturar dependencias de largo plazo. Es ideal para conjuntos de datos donde la eficiencia y la velocidad de entrenamiento son prioritarias.

- **LSTM con Mecanismo de Atención:** Como mejora sobre la LSTM estándar, se implementó una capa de atención. En lugar de utilizar únicamente el último estado oculto para predecir, el mecanismo de atención calcula un "peso" o importancia para cada uno de los 7 días de la ventana de entrada. Esto permite al modelo "enfocarse" en días específicos (por ejemplo, detectar que los datos de hace 3 días son más relevantes para la predicción de hoy que los de hace 7), mejorando la precisión en series temporales con alta volatilidad.

5 Análisis de los resultados

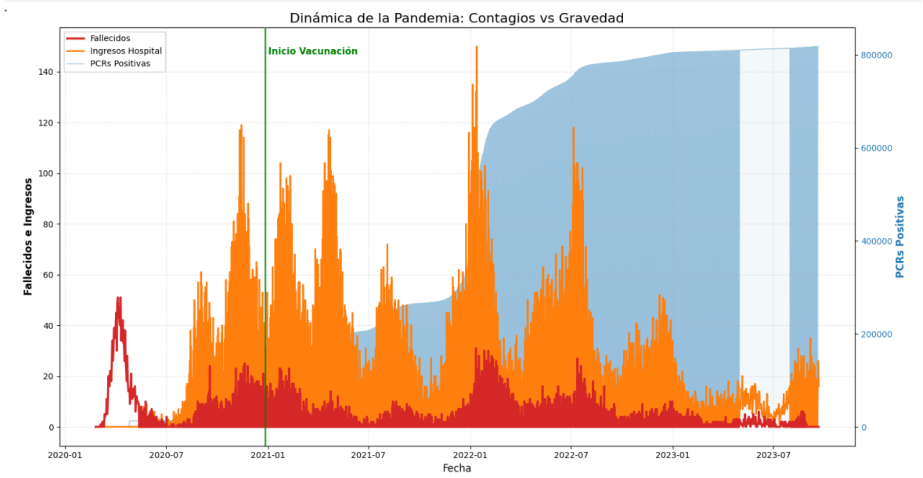

Figure 2: Dinámica de la Pandemia: Contagios vs Gravedad

5.1 Comportamiento de los Datos

Antes de evaluar el rendimiento de los modelos recurrentes, es muy importante analizar la naturaleza de la serie temporal utilizada. Como se observa en la imagen, la dinámica de la pandemia presenta desafíos críticos para cualquier algoritmo de aprendizaje automático:

- **Ruido Administrativo:** Las curvas de fallecidos e ingresos muestran un patrón de "diente de sierra" muy pronunciado. Este fenómeno responde al retraso en las actualizaciones de los datos durante los fines de semana y no a una fluctuación biológica real. Los modelos intentan predecir estas caídas y picos artificiales, lo que eleva el error absoluto (MAE).

- **Desfase Temporal (Lag):** Existe un retardo visualmente evidente entre el pico de ingresos hospitalarios y el pico de fallecimientos. Dado que nuestra ventana temporal es de 7 días, el modelo tiene dificultades para capturar relaciones de causalidad que ocurren en periodos superiores a una semana.

- **Desacoplamiento por Vacunación:** Tras la línea marcada como "Inicio Vacunación", la relación entre PCRs positivas y fallecimientos cambia drásticamente (*data drift*). Un modelo que ha aprendido de la primera ola tenderá a sobreestimar las muertes en las olas posteriores.

5.2 Evaluación de los Modelos - Opción 1

Para contextualizar el rendimiento de las redes recurrentes en el escenario cronológico, se evaluaron dos modelos de referencia que establecen el error mínimo a batir.

Modelo	**Scaled RMSE**	**Scaled MAE**
Persistencia (Naive)	0.0373	0.0270
Regresión Ridge	0.0400	0.0332

Table 1: Resultados de los modelos Baseline en el escenario cronológico (datos escalados 0-1).

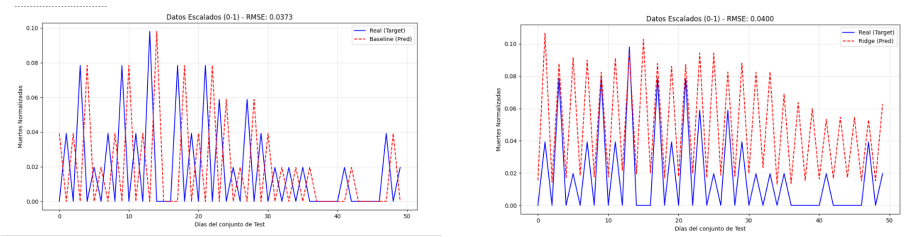

(a) Predicción Modelo de Persistencia. (b) Predicción Modelo Ridge.

Figure 3: Comparativa de resultados en modelos Baseline.

Análisis de los Baselines: El modelo de persistencia (RMSE: 0.0373) continúa superando a la Regresión Ridge (RMSE: 0.0400), lo que confirma una fuerte inercia de corto plazo en la serie temporal. Visualmente, la Figura muestra cómo el Ridge presenta dificultades para capturar los picos ruidosos de la serie.

5.2.1 Resultados de las Arquitecturas de Aprendizaje Profundo

Tras establecer los baselines, se evaluaron las redes neuronales bajo la misma partición cronológica. Los resultados reflejan la capacidad de las redes para generalizar patrones epidemiológicos complejos.

Modelo	**Val Loss (MSE Scaled)**	**RMSE Real**	**MAE Real**
Persistencia (Baseline)	0.0373 (RMSE)	-	-
MLP	0.003597 (Test Loss)	-	-
LSTM	**0.00159**	**2.38**	**1.68**
GRU	0.00374	3.12	-
LSTM + Atención	0.00159	2.38	1.68

Table 2: Métricas comparativas finales en el escenario cronológico.

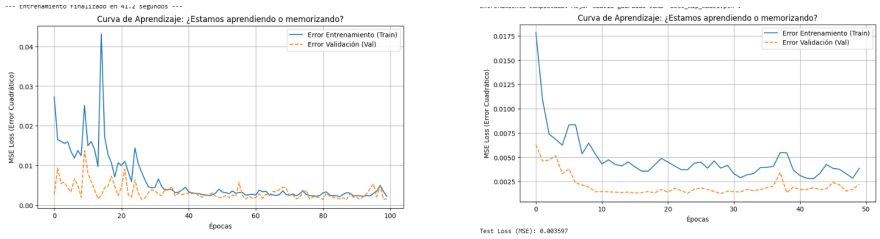

(a) Curva de Aprendizaje LSTM.

(b) Curva de Aprendizaje MLP.

Figure 4: Evolución del error (MSE) en las dos arquitecturas principales bajo partición cronológica.

5.2.2 Análisis de los Modelos

- La arquitectura LSTM se mantiene como la más precisa con un **MAE de 1.68 muertes/día**. Su curva de aprendizaje muestra una convergencia estable tras las fluctuaciones iniciales, logrando un error de validación final de 0.00159.
- **Comportamiento del MLP:** El modelo MLP registró un error de test de 0.003597. Al analizar su curva de aprendizaje, se observa mucha más inestabilidad y altibajos en comparación con las redes recurrentes. Esto puede ocurrir porque, al trabajar con una partición cronológica, el orden de los días es fundamental; sin embargo, el MLP aplana la ventana de 7 días, tratándolos como un bloque de datos desordenado en lugar de una secuencia lógica. Esta pérdida de la estructura temporal hace que al modelo le cueste más converger de forma suave, lo que se refleja en una gráfica de entrenamiento bastante ruidosa
- **Inestabilidad en la GRU:** En esta ejecución, la unidad GRU presentó un rendimiento inferior con un **RMSE real de 3.12**. La curva de pérdida revela una alta inestabilidad tanto en entrenamiento como en validación, lo que sugiere que la simplificación de sus puertas (*gates*) la hace más sensible al ruido administrativo de la serie temporal.
- **Impacto de la Atención:** El mecanismo de atención igualó el rendimiento de la LSTM base (0.00159). No obstante, su curva de aprendizaje muestra picos de inestabilidad significativos cerca de la época 20, evidenciando una mayor dificultad para converger en comparación con la LSTM estándar.

5.3 Evaluación de los Modelos - Opción 2

Bajo el esquema de partición aleatoria, los modelos de referencia muestran un comportamiento mucho más dinámico al haber sido entrenados con una distribución homogénea de todas las fases de la pandemia. Los resultados reflejan un cambio de escala respecto al escenario cronológico debido a la nueva distribución del conjunto de test.

Modelo	Scaled RMSE	Scaled MAE
Persistencia (Naive)	2.38	6.3844
Regresión Ridge	2.6122	1.5365

Table 3: Resultados de los modelos Baseline con partición aleatoria.

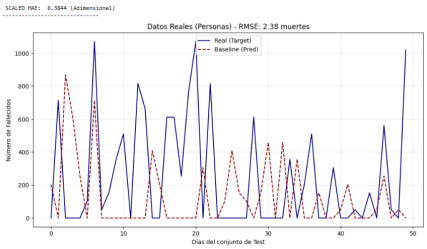

(a) Predicción Modelo de Persistencia.

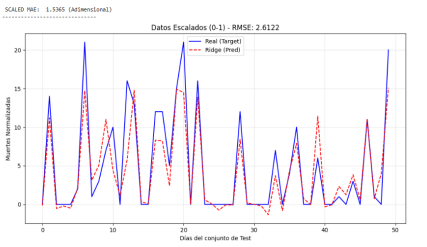

(b) Predicción Modelo Ridge.

Figure 5: Comparativa de resultados en modelos Baseline bajo escenario aleatorio.

Análisis de los Baselines:

- **Ajuste Dinámico del Ridge:** A diferencia del escenario cronológico, el modelo Ridge en esta partición logra un ajuste mucho más reactivo a los picos de la serie (Figura 5b). Con un **MAE de 1.5365**, el modelo lineal demuestra que, cuando dispone de ejemplos de todas las olas en el entrenamiento, puede mitigar gran parte del error estructural de la serie.
- **Limitaciones de la Persistencia:** El modelo de persistencia registra un **MAE de 6.3844**, reflejando la alta variabilidad de los datos barajados. Como se observa en la Figura 5a, aunque replica la estructura de los brotes, el desfase temporal de un día resulta penalizado por la mezcla de días con volatilidades muy distintas.
- **Conclusión del Escenario:** El hecho de que el Ridge se aproxime al error de persistencia en términos de RMSE (2.61 vs 2.38) sugiere que el barajado aleatorio reduce significativamente el problema del *data drift*, facilitando que modelos más sencillos capturen la dinámica general de la pandemia.

5.3.1 Resultados de las Arquitecturas de Aprendizaje Profundo

Bajo el esquema de partición aleatoria, la jerarquía de los modelos se invierte respecto al escenario cronológico. El Perceptrón Multicapa (MLP) se posiciona como la arquitectura más eficiente para procesar datos barajados, donde la memoria secuencial de las RNN deja de ser una ventaja competitiva.

Modelo	Val Loss (MSE Scaled)	RMSE Real	MAE Real
MLP	**5.6753**	-	-
LSTM + Atención	7.5737	-	140.35
LSTM	9.5023	125.69	66.69
GRU	7.4694	-	139.38

Table 4: Comparativa de redes neuronales en el escenario aleatorio

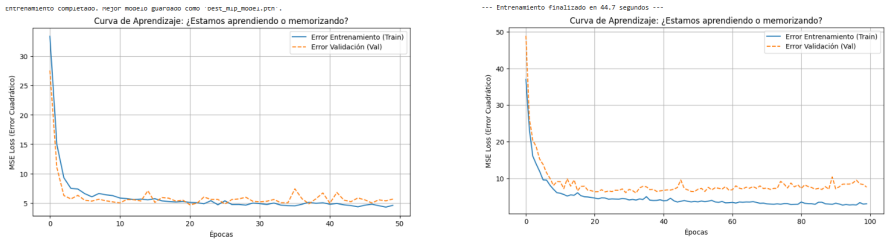

(a) Convergencia estable del MLP.

(b) Inestabilidad en LSTM + Atención.

Figure 6: Evidencia visual del escenario aleatorio: el MLP presenta un aprendizaje mucho más limpio y una menor brecha de generalización.

5.3.2 Análisis de los Modelos

- **Dominancia del MLP:** Con los datos barajados, el modelo MLP obtuvo los mejores resultados con un Val Loss de 5.6753. Al no haber una secuencia que seguir, su gráfica de aprendizaje se ve mucho más equilibrada. Esto confirma que en este escenario no hace falta la complejidad de una red recurrente; de hecho, modelos como la LSTM o la GRU funcionan peor aquí porque intentan buscar un orden que ya no existe.

- **Ineficiencia de las Redes Recurrentes:** Tanto la LSTM como la GRU presentan dificultades de convergencia. La LSTM Base registra el error más alto (**9.5023**), lo que evidencia que intentar forzar una estructura secuencial sobre datos barajados aleatoriamente perjudica la capacidad de generalización del modelo.

- **Efecto del Mecanismo de Atención:** En este contexto ruidoso, la incorporación de atención permite a la LSTM "rescatar" cierta información relevante de la ventana, bajando el error de 9.50 a **7.57**. Sin embargo, como se observa en la Figura 6b, el entrenamiento es altamente errático, con oscilaciones constantes en la pérdida de validación.

Como se puede observar el rendimiento es desastroso en comparación con la partición cronológica. Esto se debe la rotura de la dependencia temporal entre las ventanas; es decir, el modelo procesa las entradas sin ningún patrón lógico que las conecte. Debido a esto, el modelo no puede predecir el futuro porque

ha perdido la noción del "tiempo".

Los resultados nos confirman empíricamente que en las series temporales no se debe romper el orden del tiempo y que el modelo necesita observar la secuencia histórica intacta para poder capturar las tendencias epidemiológicas, validando así el uso de una partición cronológica.

5.4 Enfoque de Aprendizaje Espacial: Graph Neural Networks (GNN)

Para trascender el análisis de series temporales independientes, se implementó un enfoque basado en grafos que permite capturar la propagación del virus entre nodos interconectados. Mientras que los modelos anteriores (LSTM/GRU) se centraron en la predicción de mortalidad global, el objetivo de este modelo es predecir la **incidencia de contagios (Nuevos Positivos)** a nivel local. Se asume que la dinámica epidemiológica de una Zona Básica de Salud (ZBS) no es un fenómeno aislado, sino que está vinculada al comportamiento de su entorno funcional.

5.4.1 Inferencia de la Topología: El Grafo de Correlación

Ante la ausencia de coordenadas geográficas explícitas para definir la contigüidad física, se diseñó una solución técnica basada en la inferencia de topología mediante sincronía temporal:

- **Nodos (V):** Representan cada una de las Zonas Básicas de Salud (ZBS) analizadas.
- **Aristas (E):** La conectividad se define mediante la matriz de correlación de Pearson entre las curvas de contagio de las distintas zonas.
- **Criterio de Adyacencia:** Se asume que una correlación elevada ($\rho > 0.7$) justifica una arista, interpretando la similitud temporal como una "vecindad funcional" derivada de flujos de población comunes.

5.4.2 Arquitectura GCN y Procesamiento Espacial

Se utilizó una arquitectura de Redes Convolucionales de Grafos (GCN) para procesar esta estructura mediante la siguiente operación de convolución:

$$H^{(l+1)} = \sigma(\hat{A}H^{(l)}W^{(l)}) \tag{1}$$

Donde $\hat{A}$ es la matriz de adyacencia normalizada. Esta operación permite que la predicción incorpore la "señal de alerta" de zonas afines, mitigando el impacto del ruido administrativo individual mediante el apoyo en la tendencia colectiva de la vecindad.

5.4.3 Optimización mediante Grid Search y Resultados Finales

La efectividad del modelo se validó mediante un proceso sistemático de *Grid Search*, evaluando el impacto del *learning rate* (LR), la dimensión oculta y el *dropout*.

- **Configuración Óptima:** El modelo ganador utiliza un **LR de 0.01**, una **Dimensión Oculta de 32** y un **Dropout de 0.3**.
- **Análisis de Errores:** Se observó una alta sensibilidad al *dropout*; valores de 0.5 elevaron el Val Loss hasta 0.01328, mientras que la configuración óptima logró un **Val Loss de 0.00029**.
- **Desempeño Real:** Tras 1000 épocas de entrenamiento, el modelo GNN alcanzó un **MAE de 1.34 casos** (Error Medio por Zona y Día).

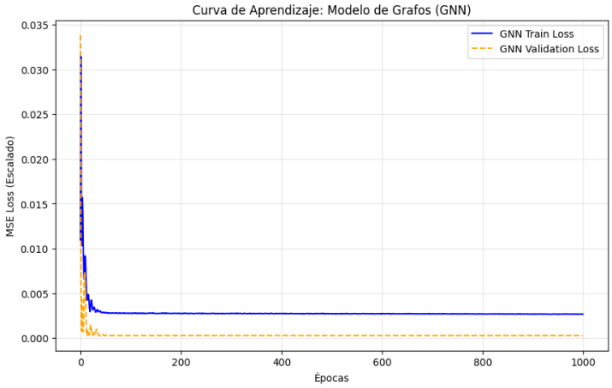

Figure 7: Curva de aprendizaje del modelo GNN. Se observa una convergencia extremadamente estable hacia un Val Loss de 0.00029.

5.4.4 Discusión Comparativa

El modelo de grafos ha demostrado ser altamente eficaz en su dominio específico. Es importante distinguir que, mientras la LSTM analiza la mortalidad agregada de toda la comunidad, la GNN aborda la predicción de contagios con granuralidad local.

El bajo error de validación obtenido (0.00029) en comparación con los modelos globales sugiere que la señal de contagios, al ser más densa y estar interconectada espacialmente, permite un aprendizaje más estable que la variable de fallecidos. La gran ventaja de este enfoque es que, al integrar la información de las 'zonas vecinas', el modelo logra distinguir si un repunte de casos es un evento aislado (ruido) o parte de una tendencia regional, validando la hipótesis de la interconexión funcional.

6 Resultados en test

Tras analizar todos los enfoques y modelos, el que mejor ha funcionado para solucionar nuestro problema de la predicción de muertes en un día dados los datos de los 7 días anteriores es el modelo LSTM con los datos ordenados de manera secuencial.
Los datos que ha obtenido este modelo en la fase de test son los siguientes:

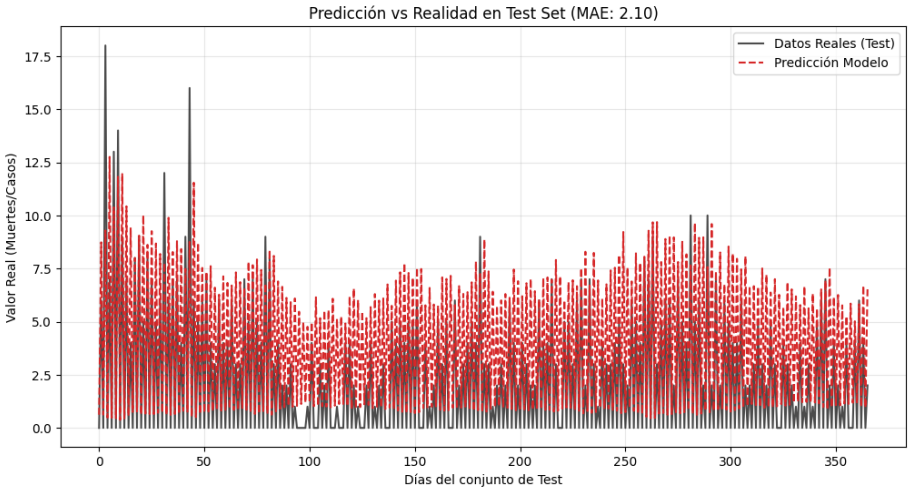

Figure 8: Resultados en test para el modelo LSTM con orden de datos secuencial

RESULTADOS FINALES (Escala Real):

- **MAE:** 2.0963 (Error medio absoluto),
- **RMSE:** 2.8018 (Raíz del error cuadrático medio)

7 Conclusiones

Tras la evaluación de las arquitecturas implementadas, se presentan las siguientes conclusiones:

- **Gran rendimiento del baseline persistente:** Una de las observaciones más relevantes ha sido la eficacia del baseline persistente. Contrario a la suposición inicial, predecir que los valores de hoy serán iguales a los de ayer ofrece una aproximación competitiva debido a la inercia temporal de la pandemia, donde las variaciones diarias no suelen ser abruptas.
- **Eficacia del Aprendizaje Espacial (GNN):** La GNN se consolida como una buena arquitectura para el monitoreo de la transmisión del virus por zonas. Al integrar la "vecindad funcional", logró un MAE real

de 1.34 casos por zona. Esto confirma que la propagación de la COVID-19 se modela muy bien como un sistema de nodos interconectados.

- **Sensibilidad a la Partición de Datos:** Se ha evidenciado un contraste crítico entre escenarios. En la validación cronológica (Opción 1), la **LSTM** fue la más robusta para predecir mortalidad (**MAE: 1.68**), mientras que en el escenario aleatorio (Opción 2), el **MLP** resultó ser el más eficiente (**Val Loss: 5.6753**) al simplificarse el problema a una regresión estática sin dependencia temporal, lo que nos permite observar que los modelos recurrentes son muy sensibles al orden de la secuencia y que no podemos alterarlo, ya que en caso de hacerlo, un modelo tan simple como el MLP superaría sus resultados.

- **Optimización y Robustez:** El *Grid Search* en la GNN demostró que un *dropout* moderado (0.3) es vital para el intercambio de información entre nodos; niveles superiores degradan la comunicación y disparan el error.

- **Limitaciones Técnicas e Interpretación:** Es necesario mencionar que el proceso de desescalado (*inverse transform*) de las métricas de error presentó desafíos técnicos debido a la sensibilidad de la transformación ante valores atípicos. Si bien las curvas de pérdida normalizadas (Loss) confirman una convergencia robusta y un aprendizaje correcto de los patrones, los valores absolutos desescalados deben interpretarse con cautela, priorizando el análisis de tendencias sobre la magnitud exacta del error. Es decir, el error en muertes reales no es excato, sino que es un cálculo aproximado dependiendo de las predicciones escaladas del modelo. Por esto, nos gustaría apuntar que no hemos conseguido obtener datos exactos desescalados. Nuestro objetivo era mostrarlos de esta manera para que los resultados fuesen más visibles, pero no hemos conseguido dar con los valores reales, por lo tanto en algunos casos parece que los resultados desescalados son inconsistentes con respecto a los escalados, que son los valores de pérdida correctos calculadas por el modelo.

7.1 Trabajo Futuro

Se propone evolucionar hacia un **Grafo Dinámico** basado en datos de movilidad en tiempo real. Asimismo, el uso de Redes de Atención de Grafos (GAT) permitiría aprender autónomamente qué zonas tienen mayor influencia sobre otras en cada fase, mejorando la respuesta ante futuros brotes.

Así mismo, se propone encontrar una manera correcta de desescalar los valores de pérdida para tener una visión realista del error de muertes que cometen los modelos al predecirlas.

7.2 Enlace a la carpeta de trabajo

Carpeta de Google Drive